EKSPLORACJA DANYCH · WYKŁAD 1

Krajobraz analizy danych

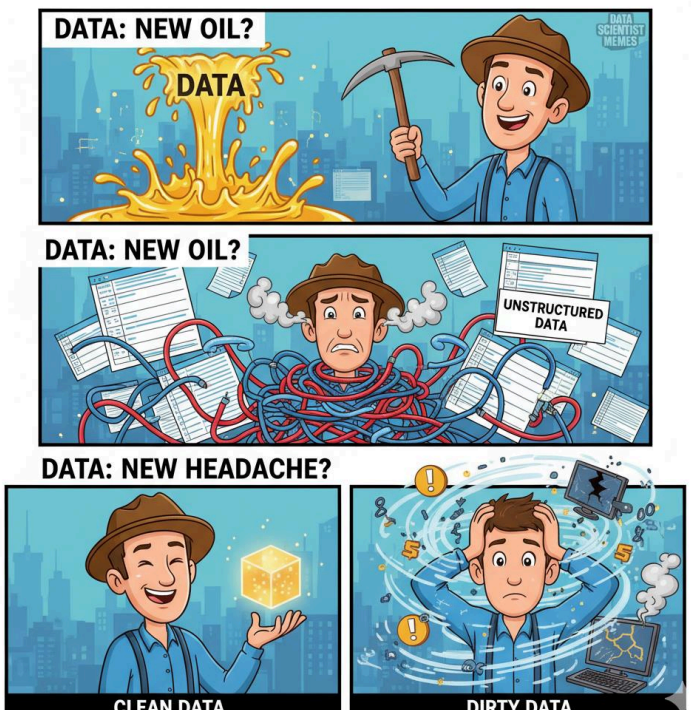
dr Paweł Gliwny
Wydział Fizyki i Informatyki Stosowanej, Uniwersytet Łódzki

✎ rok akademicki

Nasz przedmiot: Eksploracja danych

Dane: **nowa ropa naftowa** czy **nowy ból głowy**?

- Surowe dane rzadko nadają się do użycia od razu.
- Większość pracy analityka to **zrozumienie i uporządkowanie** danych — i o tym jest ten przedmiot.



Źródło: grafika wygenerowana w Gemini

Czym jest eksploracja danych?

- **Eksploracyjna analiza danych** (ang. *Exploratory Data Analysis*, EDA) — termin spopularyzowany przez Johna Tukeya (1977).
- Cel: poznać dane **zanim** zbudujemy model — rozkłady, braki, wartości odstające, zależności.
- Główne narzędzia: statystyki opisowe i **wizualizacja**.



W praktyce proces jest iteracyjny — eksploracja często odsyła nas z powrotem do czyszczenia.

Plan przedmiotu

1. Krajobraz analizy danych
2. EDA (Ekploracyjna analiza danych), brakujące wartości
3. Regresjai i Klasyfikacja
4. Klasteryzacja
5. Redukcja wymiarowości
6. Deep Learning w EDA

1

Czym są dane?

„Jeśli mamy dane, przyjrzyjmy się danym. Jeśli mamy tylko opinie, postępujmy według moich”.

— Jim Barksdale, były CEO firmy Netscape

Dane a informacje

- **Informacje** to wiedza pochodna — czerpana z mierzenia procesu, myślenia o czymś nowym, debatowania.
- Od czujników w satelitach po neurony w naszych mózgach — nieustannie powstają nowe informacje.
- Komunikowanie i rejestrowanie tych informacji nie zawsze jest proste.
- Gdy zapisujemy to, czego się nauczyliśmy, **tworzymy dane**.

> **Dane są zakodowanymi informacjami.**

Przykładowy zbiór danych

Tabelę danych nazywamy **zbiorem danych** lub **ramką danych** (ang. *data frame*).

Data	Wydatki na reklamy	Sprzedaż (szt.)	Zysk	Medium
2021-01-01	2 000	100	10 425	Prasa
2021-02-01	1 000	150	15 349	Internet
2021-03-01	3 000	200	25 095	Telewizja
2021-04-01	1 000	175	12 433	Internet

Wiersz — obserwacja, rekord, krotka, próba

Kolumna — cecha, pole, atrybut, predyktor, zmienna

Punkt danych — przecięcie obserwacji i cechy: 150 szt. dnia 2021-02-01

Słownictwo nauki o danych (ang. *data science*)

- Ramki danych
- Obserwacje, rekordy, próby
- Cechy, pola, atrybuty, predyktory, zmienne
- Dane ustrukturyzowane i nieustrukturyzowane
- Statystyki zbiorcze

Każda kolumna
jest listą informacji zakodowanych w **jednakowym formacie** — w pandas każda kolumna ma jeden typ (`dtype`).

Znaj swoich rozmówców

- Dane bada się w wielu dziedzinach, a każda ma własny żargon.
- Te same rzeczy często mają różne nazwy.
- Częścią pracy specjalisty od danych jest rozmawianie z **różnymi grupami** z uwzględnieniem ich języka i preferencji.

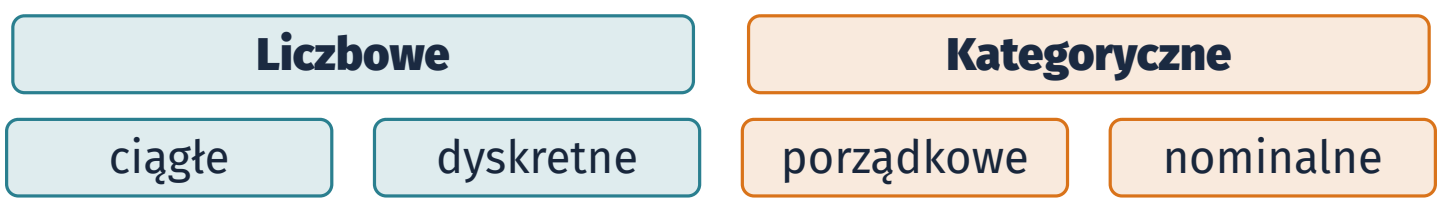


2

Typy danych

Typy danych

- Dwa najczęstsze typy danych: **liczbowe** i **kategoryczne**.
- Dane liczbowe to głównie liczby, czasem z symbolami jednostek.
- Dane kategoryczne to słowa, symbole, frazy — i (myląco) czasem liczby, np. **kody pocztowe**.



Typy danych liczbowych

Dane ciągłe

- Mogą przyjmować **dowolną wartość** z przedziału na osi liczbowej — zbiór wartości jest nieprzeliczalny.
- Przykład: temperatura powietrza.

Dane dyskretne

- Przyjmują wartości z **przeliczalnego** zbioru — zwykle są to zliczenia.
- Przykład: liczba posiadanych samochodów: 0, 1, 2... ale nie 1,23.
- Nie zawsze są to liczby całkowite: rozmiar buta (42,5) czy kwota w groszach też są dyskretne.

Dane kategoryczne porządkowe

Dane **uporządkowane** (porządkowe) mają wewnętrzną kolejność.

- Ankiety: „Oceń wrażenia w skali od 1 do 10”.
- Nie muszą być zakodowane liczbami — np. rozmiary koszulek: S, M, L, XL.

Uwaga

Odległości między kategoriami nie muszą być równe — różnica między „M” a „L” nie jest „tą samą” wielkością co między „L” a „XL”.

Dane kategoryczne nominalne

Dane **nieuporządkowane** (nominalne) nie mają wewnętrznej kolejności.

- Cecha „Medium”: Prasa, Internet, Telewizja.
- Odpowiedź „Tak” / „Nie” na pytanie: „Kibicujesz Widzewowi?”
- Kolejność prezentacji jest dowolna — żadna kategoria nie jest „większa” od innej.

Jaki to typ danych?

Zmienna	Typ
Temperatura powietrza w Łodzi	
Liczba samochodów w gospodarstwie	
Rozmiar koszulki (S, M, L, XL)	
Kod pocztowy 90-236	
Ocena wykładu w skali 1–10	
Kibic Widzewa / ŁKS	

Jaki to typ danych?

Zmienna	Typ
Temperatura powietrza w Łodzi	liczbowa ciągła
Liczba samochodów w gospodarstwie	liczbowa dyskretna
Rozmiar koszulki (S, M, L, XL)	porządkowa
Kod pocztowy 90-236	nominalna
Ocena wykładu w skali 1–10	porządkowa
Kibic Widzewa / ŁKS	nominalna

Kod pocztowy wygląda jak liczba, ale średnia z kodów pocztowych nie ma sensu.

3

Jak zbiera się dane?

Obserwacyjne czy eksperymentalne?

Dane można klasyfikować według tego, **jak je zebrano** i **jaką mają strukturę**.

Dane obserwacyjne
Zbierane przez osoby lub systemy **pasywnie obserwujące** proces (czujniki, oprogramowanie monitorujące).

Dane eksperymentalne
Zbierane zgodnie z metodą naukową: badacz **ingeruje** w proces według ustalonej metodyki, zwykle z **losowym** przydziałem.

Dane obserwacyjne

Większość danych w firmach (i na świecie) ma charakter obserwacyjny.

- Przykłady: liczba wizyt na stronie, dzienna sprzedaż, liczba e-maili.
- Mogą być zapisywane celowo lub przy okazji.
- Powstają jako produkt uboczny działalności: transakcje, płatności, media społecznościowe.
- Często trafiają do baz danych „na później”.
- Zbiera się je także świadomie — np. ankiety i sondaże.

Dane eksperymentalne

- Gromadzi się je **celowo i metodycznie**, aby odpowiedzieć na konkretne pytanie.
- „Złoty standard” danych dla statystyków i badaczy.
- Procedurę (np. lek) stosuje się do **losowo wybranych** osób lub obiektów.
- Przykład: badania kliniczne leków.

Badanie kliniczne leku

- Pacjentów dzieli się **losowo** na dwie grupy: badaną i kontrolną.
- Grupa badana otrzymuje lek, grupa kontrolna — placebo.
- Losowy przydział równoważy czynniki nieistotne dla badania:
  - wiek, status socjoekonomiczny, masa ciała...
  - grupy stają się podobne we wszystkim **poza leczeniem**,
  - co pozwala wyizolować efekt leczenia
  - i eliminuje wpływ czynników zakłócających.

Eksperymenty A/B

- Stosowane w wielu branżach — od badań leków po marketing.
- W marketingu cyfrowym:
  - projektanci stron testują różne układy i reklamy,
  - „rzut monetą” decyduje, czy użytkownik zobaczy wersję A czy B,
  - po wizytach tysięcy użytkowników porównuje się klikalność.
- Randomizacja równoważy inne cechy — porę dnia, typ internauty itp.

Zastosowanie i korzyści testów A/B

Zastosowanie

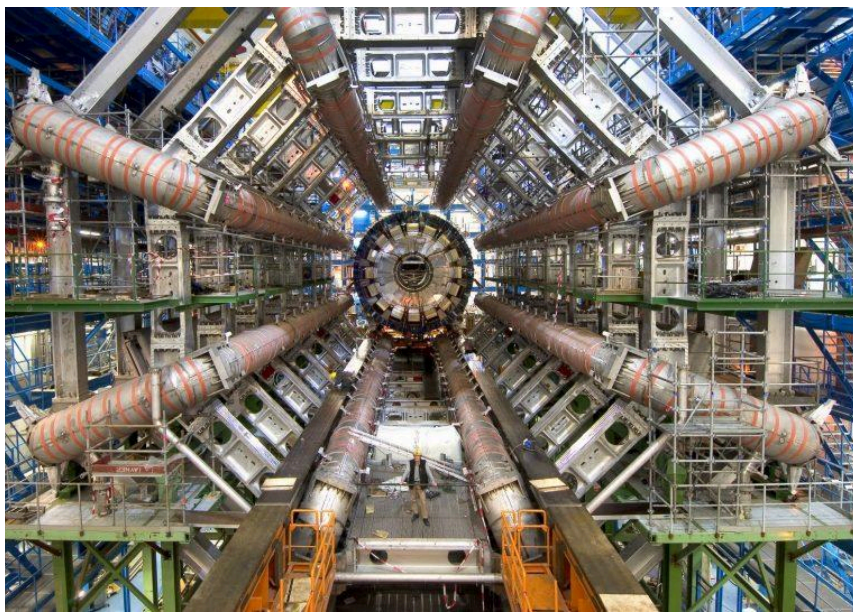
- Sprawdzenie, która wersja generuje więcej kliknięć.
- Reklamy A i B wyświetlane losowo, wyniki analizowane po zebraniu danych.

Korzyści

- Obiektywna ocena skuteczności wersji (stron, reklam).
- Minimalizacja wpływu zmiennych zakłócających dzięki randomizacji.

Czy dane z LHC albo z teleskopu są eksperymentalne?

- Fizyk powie: **eksperyment** — kontrolujemy aparaturę i warunki pomiaru.
- Statystyk zapyta: **czy była randomizacja?** Czy badacz przydzielał „leczenie”?
- Astronom nie przydziela gwiazdom warunków — obserwuje Wszechświat taki, jaki jest.



Pytanie do sali

Do której kategorii należą dane z teleskopów JWST, Rubin czy MAGIC — i co z tego wynika dla wnioskowania o przyczynach?

Źródło: CERN — detektor ATLAS

4

Struktura danych

Dane ustrukturyzowane i nieustrukturyzowane

Ustrukturyzowane
Wyglądają jak arkusz kalkulacyjny lub tabela w bazie danych — uporządkowane w **wiersze i kolumny**.

Nieustrukturyzowane
Tekst recenzji, zdjęcia, filmy, pliki dźwiękowe. Trzeba je **przekształcić** w postać ustrukturyzowaną, zanim zastosujemy metody analityczne.

Dane ustrukturyzowane (ang. *structured data*)

Informacje o ściśle zdefiniowanym, z góry narzuconym **modelu danych**.

- Struktura (nazwy kolumn, typy, relacje) jest określona **przed** wprowadzeniem danych.
- Łatwo je przeszukiwać, sortować i filtrować standardowymi zapytaniami, np. SQL.
- Głównie dane ilościowe: liczby, daty, krótkie zdefiniowane teksty.
- Przechowywane zwykle w relacyjnych bazach danych (np. MySQL, PostgreSQL) lub hurtowniach danych.

Przykłady danych ustrukturyzowanych

- **Baza klientów sklepu:**

  `ID_Klienta`, `Imie`, `Nazwisko`, `Email`, `Data_Urodzenia`

- **Dane transakcyjne:**

  `ID_Transakcji`, `ID_Produktu`, `Cena`, `Ilosc`, `Data_Zakupu`

- **Czujniki IoT** (odczyt co minutę):

  `ID_Czujnika`, `Znacznik_Czasu`, `Temperatura`, `Wilgotnosc`

- **Arkusz kalkulacyjny Excela** — klasyczny przykład danych tabelarycznych.

Dane nieustrukturyzowane (ang. *unstructured data*)

- Nie mają z góry narzuconego schematu — istnieją w „surowej”, natywnej formie.
- Według często cytowanych szacunków stanowią **80–90%** danych wytwarzanych na świecie.
- Ich analiza jest trudniejsza: najpierw trzeba nadać im strukturę albo wydobyć z nich istotne cechy.

Cechy danych nieustrukturyzowanych

- **Brak schematu:** nie mają predefiniowanej struktury tabelarycznej.
- **Trudne przeszukiwanie:** standardowe narzędzia bazodanowe nie wystarczają — potrzebne są zaawansowane algorytmy.
- **Głównie dane jakościowe:** tekst, obraz, dźwięk, wideo.
- **Przechowywanie:** nierelacyjne bazy danych (NoSQL), jeziora danych (*data lakes*), systemy plików i magazyny obiektów (np. Amazon S3, HDFS).

Dane nieustrukturyzowane: tekst

- **Tekst:** e-maile, posty, recenzje produktów, artykuły, dokumenty PDF.
- **Analiza:** przetwarzanie języka naturalnego (**NLP**) — analiza sentymentu, ekstrakcja słów kluczowych, klasyfikacja tematów.

```
# pip install -U spacy
# python -m spacy download en_core_web_sm
import spacy

nlp = spacy.load("en_core_web_sm")
text = ("When Sebastian Thrun started working "
        "on self-driving cars at Google in 2007, "
        "few people outside of the company "
        "took him seriously.")
doc = nlp(text)

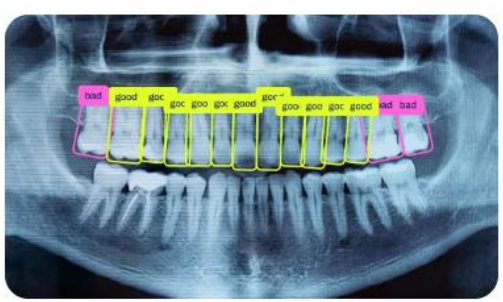
# Frazy rzeczownikowe i czasowniki
print([c.text for c in doc.noun_chunks])
print([t.lemma_ for t in doc if t.pos_ == "VERB"])

# Jednostki nazwane (NER)
for ent in doc.ents:
    print(ent.text, ent.label_)
```

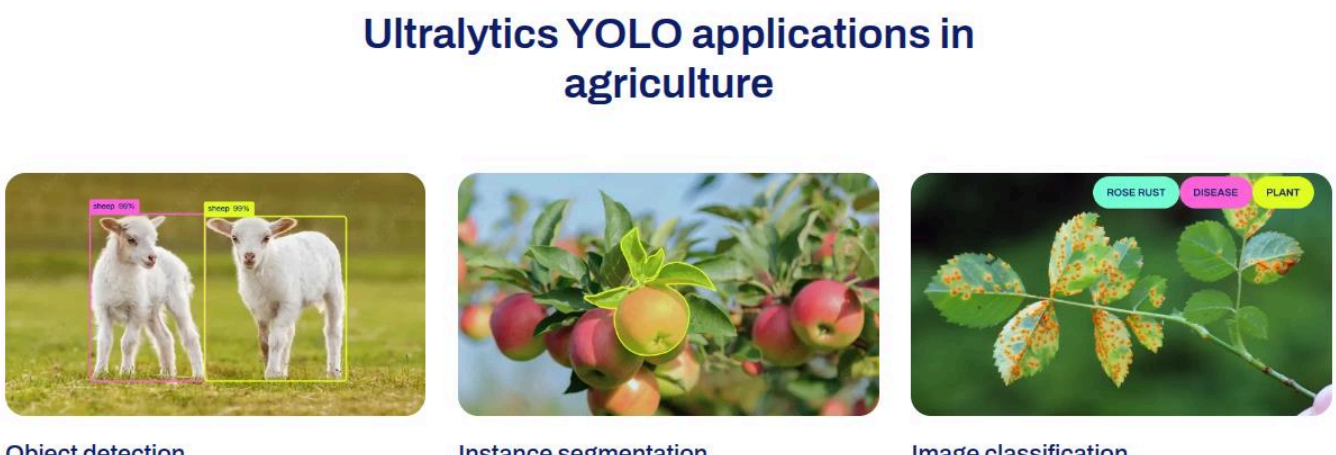
Źródło: przykład z dokumentacji spaCy (spacy.io)

Dane nieustrukturyzowane: obrazy

- **Obrazy:** zdjęcia w mediach społecznościowych, skany dokumentów, zdjęcia satelitarne, obraz z monitoringu.
- **Analiza:** widzenie komputerowe (*computer vision*) — rozpoznawanie obiektów, identyfikacja twarzy, analiza obrazów medycznych.



OBB object detection



Źródło: Ultralytics YOLO — materiały producenta

Dane nieustrukturyzowane: wideo i dźwięk

Wideo

- Filmy na YouTube, nagrania z wideokonferencji, monitoring miejski.
- Analiza jak dla obrazów, ale z **wymiarem czasu** — np. śledzenie ruchu obiektów.

Dźwięk

- Pliki MP3, nagrania rozmów w call center, podcasty, nagrania przyrodnicze.
- Przetwarzanie sygnałów audio — transkrypcja mowy (*speech-to-text*), identyfikacja mówcy.

A co pomiędzy? Dane semistrukturalne

- Trzecia kategoria (ang. *semi-structured data*).
- Nie pasują do sztywnego schematu relacyjnej bazy danych...
- ...ale zawierają **znaczniki lub metadane**, które pozwalają je organizować hierarchicznie.
- Przykłady: pliki **JSON** i **XML** — struktura oparta na znacznikach i zagnieżdżeniach.
- Elastyczne, a przy tym łatwiejsze do przetwarzania maszynowego niż czysty tekst.

```
{
  "uzytkownik": {
    "imie": "Anna",
    "nazwisko": "Kowalska",
    "email": "anna.k@example.com",
    "zainteresowania": [
      "analiza danych", "AI", "rower"
    ]
  }
}
```

Podsumowanie: struktura danych

Cecha	Ustrukturyzowane	Nieustrukturyzowane	Semistrukturalne
Struktura	z góry narzucony schemat	brak schematu	elastyczny schemat (znaczniki)
Model	relacyjny (tabele, wiersze)	natywna forma pliku	hierarchiczny (drzewo, graf)
Przykłady	arkusze Excela, bazy SQL	tekst, obraz, wideo, audio	pliki JSON, XML
Przechowywanie	relacyjne bazy danych (SQL)	bazy NoSQL, jeziora danych	bazy NoSQL (np. dokumentowe)
Analiza	łatwa, głównie SQL	złożona (NLP, CV), wymaga AI/ML	umiarkowanie złożona

Dlaczego to jest ważne?

Narzędzia i techniki analityczne zależą od **rodzaju danych**.

- Samo zapytanie SQL znajdzie recenzje zawierające słowo „zwrot”, ale **nie powie**, czy recenzja jest pozytywna — do tego potrzebne jest NLP.
- Z kolei nie ma sensu używać zaawansowanych modeli NLP do analizy tabeli ze sprzedażą.

Współczesna analityka danych

To w dużej mierze umiejętność pracy z **każdym** rodzajem danych — zwłaszcza przekształcania danych nieustrukturyzowanych i semistrukturalnych w postać ustrukturyzowaną, na której mogą działać algorytmy uczenia maszynowego.

5

Skala danych we współczesnym świecie

YouTube

- Na platformę trafia ponad **500 godzin nowego wideo na minutę** (wartość podawana przez YouTube od 2019 r.).
- Całkowitej objętości przechowywanych danych YouTube nie publikuje — niezależne szacunki są bardzo rozbieżne.

Pytanie do sali

Ile to terabajtów dziennie? Oszacujmy: 500 h/min × 1440 min × ok. 1 GB na godzinę wideo HD ≈ ?

Źródło: YouTube / Wikipedia — hasło „YouTube”

YouTube

- Na platformę trafia ponad **500 godzin nowego wideo na minutę** (wartość podawana przez YouTube od 2019 r.).
- Całkowitej objętości przechowywanych danych YouTube nie publikuje — niezależne szacunki są bardzo rozbieżne.

Pytanie do sali

Ile to terabajtów dziennie? Oszacujmy: 500 h/min × 1440 min × ok. 1 GB na godzinę wideo HD ≈ ? **ok. 720 TB dziennie** — i to tylko nowe materiały.

Źródło: YouTube / Wikipedia — hasło „YouTube”

Dane do trenowania dużych modeli językowych (LLM)

- Modele takie jak GPT czy Llama trenuje się na ogromnych korpusach tekstu.
- **The Pile** (EleutherAI, 2020) — ok. **825 GiB** tekstu.
- **FineWeb** (Hugging Face, 2024) — ok. **15 bilionów tokenów**, czyli ok. **44 TB** oczyszczonego tekstu z sieci.
- Twórcy modeli komercyjnych (np. GPT-4) nie ujawniają swoich zbiorów — krążące liczby to jedynie szacunki.

Źródło: Gao i in. (2020), *The Pile*; Penedo i in. (2024), *FineWeb*, huggingface.co/datasets/HuggingFaceFW/fineweb

Słynny cytat byłego CEO Google

- Eric Schmidt (2010): *„co dwa dni tworzymy tyle informacji (5 eksabajtów), ile stworzyliśmy od zarania cywilizacji do 2003 roku”*.
- Dziś, w erze AI, IoT i mediów społecznościowych, tempo jest jeszcze większe.

Uwaga
Ta liczba była szeroko kwestionowana — nie wiadomo dokładnie, co i jak zmierzono. Lekcja dla analityka: **zawsze pytaj o źródło liczby**.



Dane w eksperymentach naukowych: Obserwatorium Very C. Rubin

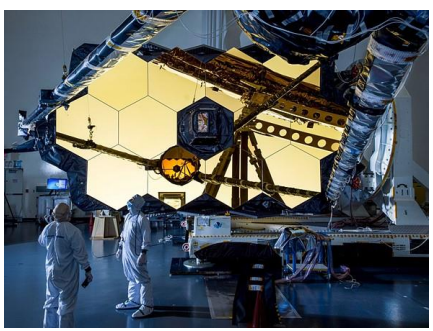
- Przegląd nieba **LSST** (*Legacy Survey of Space and Time*) — pierwsze obrazy w 2025 r.
- Ok. **20 TB** surowych danych **każdej nocy**.
- W ciągu 10 lat: ok. **60 PB** surowych danych i katalog ok. **20 PB**.
- Całość po przetworzeniu: **setki petabajtów**.

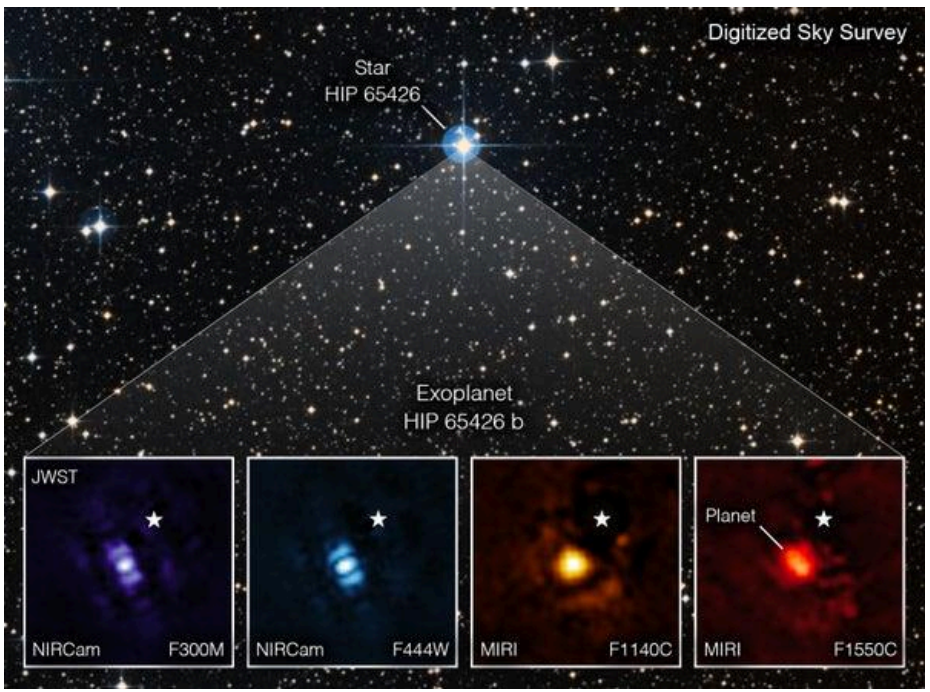


Źródło: Rubin Observatory — Data Management (lsst.org)

Dane w eksperymentach naukowych: Kosmiczny Teleskop Jamesa Webba

- JWST przesyła na Ziemię ok. **57 GB danych dziennie**.
- To niezwykle złożone i cenne dane, które zmieniają astronomię.

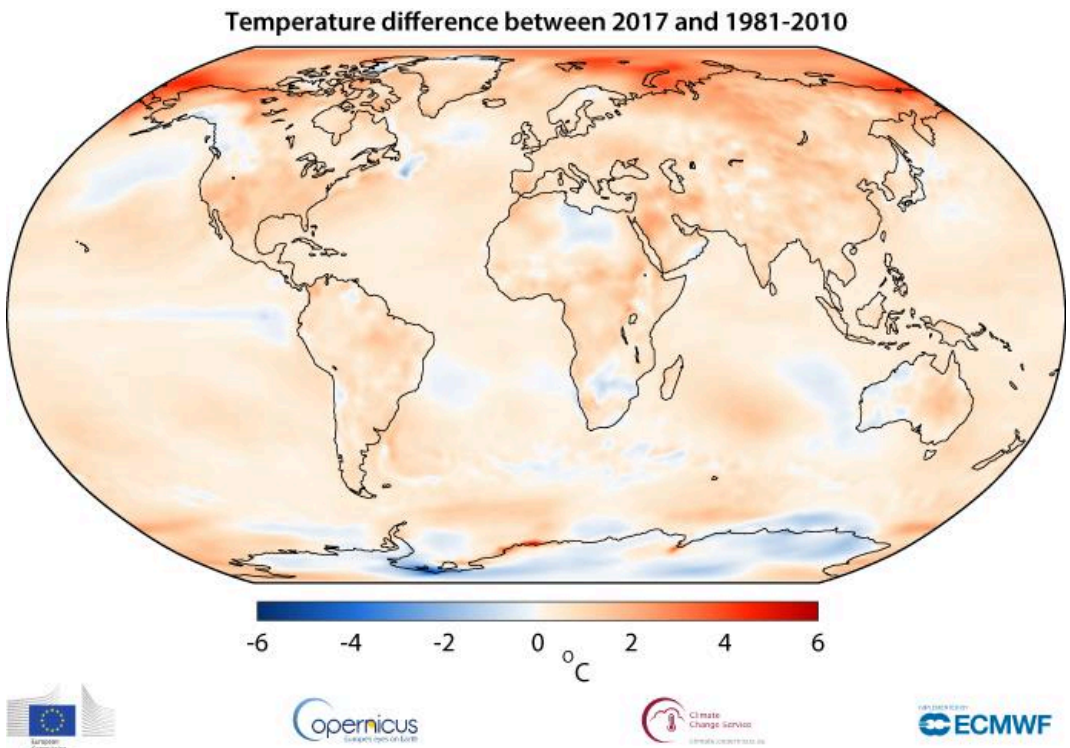




Źródło: NASA / STScI; zdjęcie egzoplanety HIP 65426 b — NASA/ESA/CSA

Dane klimatyczne

- Współczesne centra danych klimatycznych przechowują **setki petabajtów** informacji.
- Przykład: **ERA5** — globalna reanaliza klimatu, ok. **5 PB**.
- Zarządza nią **Europejskie Centrum Prognoz Średnioterminowych** (ECMWF) w ramach programu **Copernicus**.



Źródło: ECMWF / Copernicus Climate Change Service

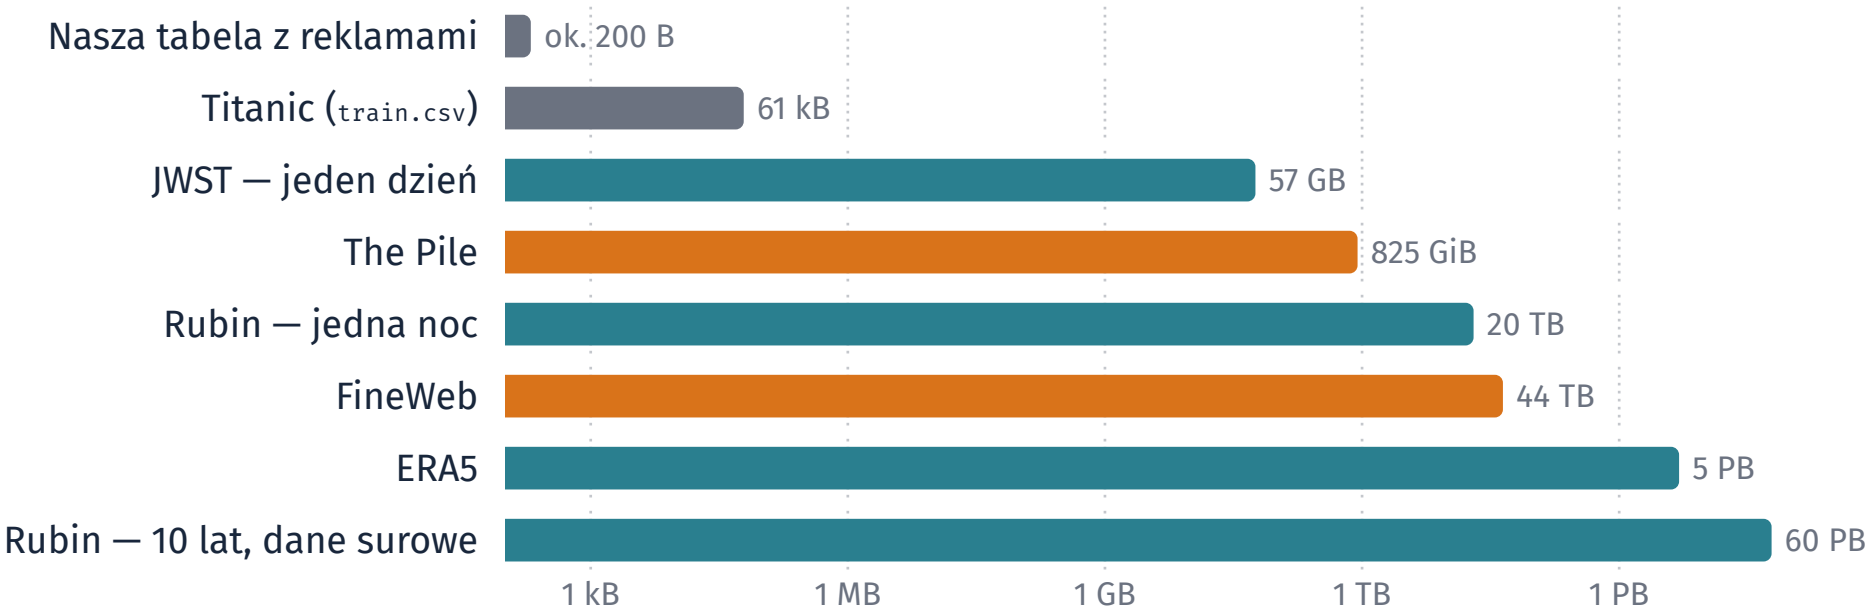
Dane z meczu piłki nożnej

- **Respo Vision** — polska firma z branży *deep tech*, która zmienia analitykę sportową za pomocą AI.
- Generuje trójwymiarowe (3D) dane o ruchu zawodników i piłki na podstawie nagrania z **jednej standardowej kamery**.
- Skala: ok. **150 milionów punktów danych** z jednego meczu.



Źródło: „Meet the startups: Respo Vision”

Skala danych w jednym spojrzeniu



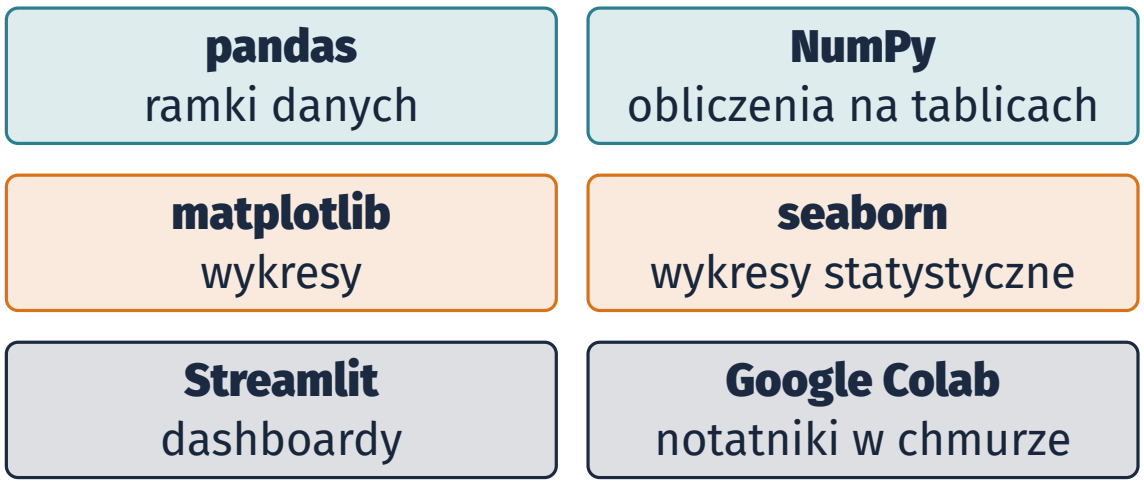
Skala logarytmiczna — każda linia to **1000 razy** więcej danych.

6

Narzędzia

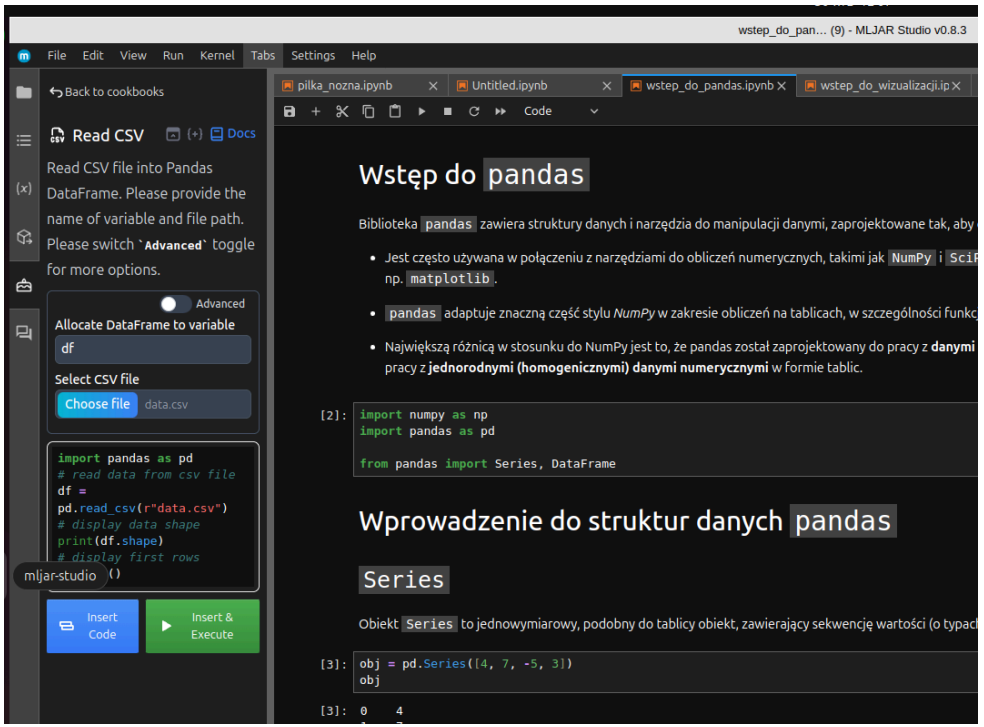
Narzędzia analityka danych

- **Języki:** Python (u nas), SQL, R, JavaScript.
- **Notatniki:** Jupyter, Google Colab.
- **Dashboardy:** Streamlit.



MLJAR Studio

- Polski produkt.
- Aplikacja desktopowa do analizy danych — **nie wymaga doświadczenia w programowaniu**.
- Generuje kod w Pythonie, który można potem samodzielnie modyfikować.
- mljar.com



7

Różne podejścia do analizy danych

Statystyka opisowa i wnioskowanie

Statystyka opisowa

- Podsumowuje zbiór danych miarami takimi jak średnia, mediana, odchylenie standardowe.
- To pierwszy krok do zrozumienia danych i wskazania, gdzie potrzebna jest głębsza analiza.

Wnioskowanie statystyczne

- Pozwala wyciągać wnioski **wykraczające poza** sam zbiór danych.
- Na podstawie próby uogólniamy na populację; przedziały ufności i testy hipotez kwantyfikują niepewność.

Prawdopodobieństwo

- Stanowi podstawę zarówno wnioskowania statystycznego, jak i wielu modeli ilościowych.
- Pozwala kwantyfikować niepewność i oceniać prawdopodobieństwo przyszłych wyników na podstawie bieżących informacji.

Optymalizacja i symulacje

- **Optymalizacja:** szukanie najlepszego rozwiązania przy zadanych ograniczeniach — np. programowanie liniowe w alokacji zasobów.
- **Symulacja:** metody Monte Carlo modelują złożone lub niepewne systemy, generując tysiące możliwych wyników — finanse, logistyka, analiza ryzyka.

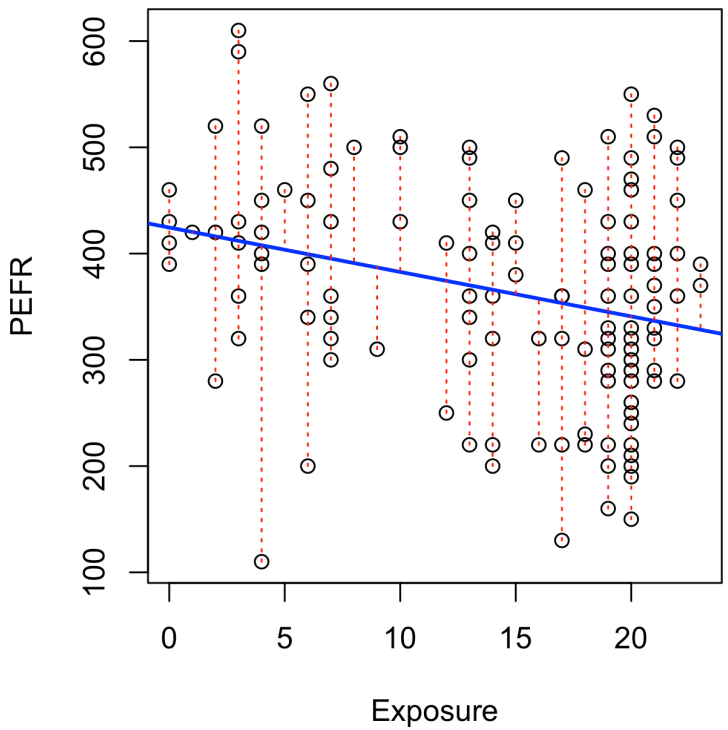
> Tym się na tym przedmiocie **nie będziemy** zajmować.

Uczenie maszynowe (ang. *machine learning*, ML)

- Opiera się na wielu zasadach statystyki.
- Algorytmy **uczą się na podstawie danych**, aby dokonywać coraz dokładniejszych prognoz lub klasyfikacji.
- ML wykracza poza tradycyjne modele statystyczne...
- ...ale ma te same korzenie: prawdopodobieństwo i optymalizację.

Analiza zależności: regresja

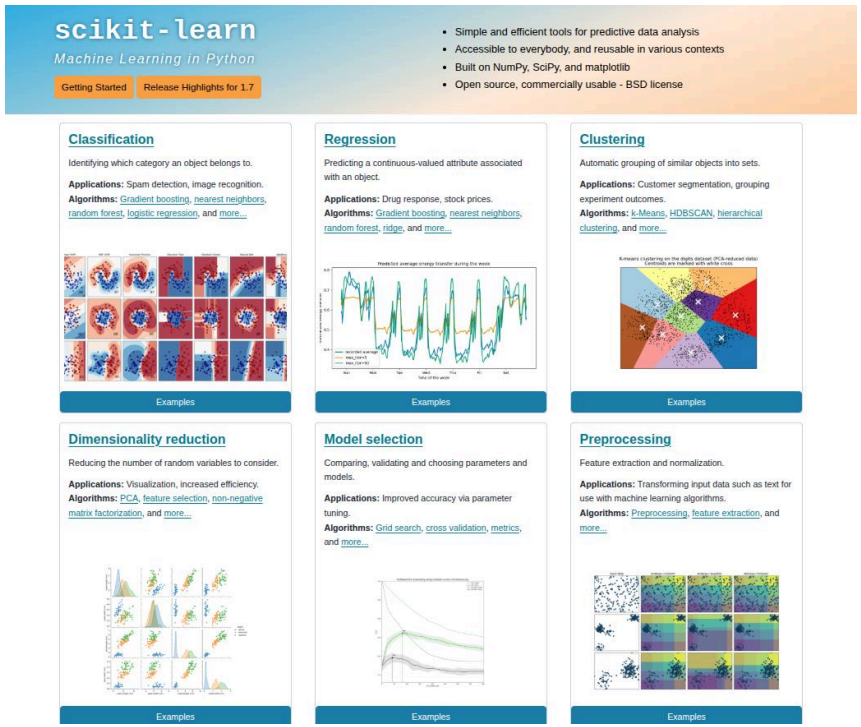
- Bada relacje między zmiennymi — jak jedna zmienna zmienia się w odpowiedzi na drugą.
- Podstawowe narzędzie modelowania trendów i prognozowania.



Źródło: P. Bruce, A. Bruce, P. Gedeck, *Statystyka praktyczna w data science* (dane LungDisease)

Techniki uczenia maszynowego

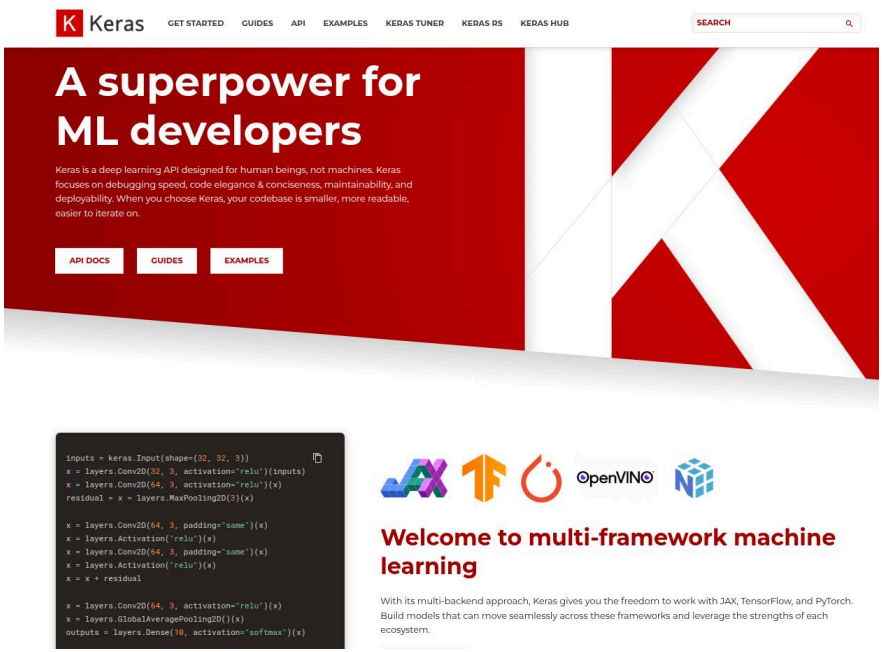
- Obejmują znane narzędzia, jak regresja liniowa...
- ...i rozszerzają je o elastyczne metody, np. **drzewa decyzyjne** i **lasy losowe**, które dobrze radzą sobie w złożonych sytuacjach.



Źródło: scikit-learn.org

Techniki uczenia głębokiego

- Opierają się na **sieciach neuronowych**.
- Rozwijają koncepcje klasycznego uczenia maszynowego, wprowadzając **modele wielowarstwowe** (np. sieci konwolucyjne i rekurencyjne).
- Potrafią **automatycznie wykrywać złożone wzorce** w danych takich jak obrazy czy tekst.



Źródło: keras.io

Zaliczenie

Wykład

- Egzamin pisemny z teorii: około 20 pytań zamkniętych i 2–3 pytania otwarte.

Laboratoria

- Zadania z każdych zajęć w postaci **notatników Jupyter** w swoim repozytorium na GitHubie.
- Wszystkie zadania oddane w terminie (do następnych zajęć) → ocena **3**.
- Na ocenę **4** i **5**: miniprojekt na własnym zbiorze danych, czyli analiza EDA, zastosowanie algorytmów uczenia maszynowego i np. **dashboard**.

AI na zajęciach

Każde (prawie) zadanie z tych laboratoriów LLM rozwiąże w kilka sekund.

Dlatego **celem nie jest zrobienie zadania** — celem jest to, żebyś **Ty** zrozumiał, jak to działa.

Możesz korzystać z asystentów AI — przy pisaniu kodu i przy nauce.

Ale oddajesz tylko kod, który rozumiesz.

Źródła

- A. J. Gutman, J. Goldmeier, *Analityk danych. Przewodnik po data science, statystyce i uczeniu maszynowym*, Helion.
- P. Bruce, A. Bruce, P. Gedeck, *Statystyka praktyczna w data science*, Helion.
- J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977.
- Rubin Observatory — Data Management: lsst.org
- G. Penedo i in., *The FineWeb Datasets*, 2024 — huggingface.co/datasets/HuggingFaceFW/fineweb
- L. Gao i in., *The Pile: An 800GB Dataset of Diverse Text for Language Modeling*, 2020.
- ECMWF / Copernicus — ERA5: cds.climate.copernicus.eu
- Dokumentacja: pandas, scikit-learn, Keras, spaCy.